关于《人工智能大模型医学应用研究》导读

本文梳理了《人工智能大模型医学应用研究》的核心内容，该研究发表于《中国科学：生命科学》2024 年第 54 卷第 3 期，由解放军总医院与清华大学团队联合完成，系统分析了人工智能大模型在医学领域的发展现状、关键技术、应用需求及研发实践，为医学大模型的创新发展提供了全面的理论与实践参考。

1 研究背景与动机

近年来，以 BERT、GPT、CLIP 为代表的人工智能大模型凭借大数据、强算力与复杂算法的深度融合，成为人工智能技术发展的重要突破，在自然语言处理、图像分析等领域实现广泛应用，也为医学人工智能的高质量发展带来新契机。Google、微软、阿里、华为等企业及北京大学、清华大学等院校联合攻关，推出 M6、PanGu、女娲、BioBART 等多款大模型，参数量与应用能力持续提升，形成了各具特色的大模型发展格局。国家先后出台《新一代人工智能发展规划》等政策，将医疗列为人工智能重要应用领域，医疗卫生事业的特殊性与重要性，也要求人工智能技术为其提供更高效的支撑。

图 1 著名大模型概况

Figure 1 Overview of popular massively large AI models

名称	发表时间	参数量（亿）	训练数据量	语种	研制单位	主要架构	训练策略	支持硬件	应用领域
MoE[25]	2017.1	1370	新闻语料库1000亿词	英语	Google	基于稀疏门控的专家层混合体，由多达数千个前馈子网络组成	引入稀疏门控专家混合层，每一个样本都有一个可训练门控网络计算稀疏组合	16~32 Tesla K40 GPUs	机器翻译 多语言翻译
GPT[2]	2018.7	1.1	语料库7000本书	英语	OpenAI	基于Transformer的特征抽取器，保留有标注的多头注意力	两阶段训练，分别采用无监督预训练语言模型和有监督的下游任务fine-tuning	GPU	文本生成
BERT[1]	2018.10	1~3	开源语料+维基百科33亿词	英语	Google	多层双向转换编码器+双向自注意力机制	使用特征提取器Transformer和语言模型实现预训练的深度双向表示	TPU	语言表征 文本分类
GPT-2[26]	2019.1	15	Web Text 40 GB	英语 法语	OpenAI	由多层单向Transformer的解码器构成一种自回归模型	以对数线性方式进行多任务小样本学习	GPU	机器问答 阅读理解 文本生成
Megatron-LM[27]	2019.9	83	聚集语料174 GB	英语	NVIDIA	PyTorch Transformer+模型并行+数据并行	采用简单高效的层内模型并行方法，并在原生PyTorch中插入通信指令	GPU V100 (512块)	自然语言处理
Turing-NLG[28]	2020.2	170	文本	英语	微软	基于Transformer的生成语言模型，通过生产单词完成开放式文本任务	基于NVIDIA DGX-2和Infini-Band实现快速通信，降低模型并行复杂度	GPU V100 (256块)	编写故事 生成答案 文本摘要
BioBERT[29]	2020.4	–	生物医学180亿词	英语	延丽大学	与BERT结构基本相同，多层双向转换编码器+双向自注意力机制	基于NSML架构，进行“BERT通用领域语料+BioBERT生物医学语料”双层预训练	GPU V100 (8块)	实体识别 关系抽取 知识问答
GPT-3[30]	2020.5	1750	文本 570 GB	英语	OpenAI	采用可替代密集和局部带状稀疏注意力机制，构建自回归语言模型	基于小样本学习策略，在每个矩阵相乘的内部以及不同网络层之间实现混合并行	GPU集群 V100	文本生成 机器问答
Oscar[31]	2020.7	–	图像文本对650万条	英语	微软 华盛顿大学	基于图像文本表示的多层Transformer建立视觉语言预处理模型	按以图像静态对象的标记信息，进行图像-文本对的表征学习	GPU Cluster	视觉语言理解 与生成等
T5[32]	2020.7	110	文本 750 GB	英语	Google	为NLP预训练提供一个文本到文本的通用框架	基于模型并行和数据并行，构建无监督/有监督的文本生成预训练任务	Cloud TPU (1024块)	语言理解 任务
Switch Transformer[20]	2021.1	16000	爬虫语料库	英语	Google	基于稀疏路由结构，每轮迭代触发部分Expert计算	采用稀疏激活模型有利于TPU计算，简化MoE路由算法	TPU	自然语言处理 机器翻译
DALL-E[4]	2021.2	120	文本图像对330万	英语	OpenAI	采用dVAE编解码+16位混合精度架构	采用两阶段训练，离散变分自编码+自回归转换器	GPU V100 (1024块)	文本图像 生成
CLIP[1]	2021.2	0.63	文本图像对4亿	英语	OpenAI	通过预训练图像编码和文本编码，建立零样本分类器	利用对比式训练、自监督学习等技术减少人工标注，将图像分类转为图文匹配	GPU V100 (592块)	文本图像 分类
M6[5]	2021.5	1000	1.9 TB图像+292 GB文本	中文	阿里 清华大学	基于多GPU架构，在每个MoE层嵌入多个Expert以充分使用内存	基于自关注+大规模预训练，建立多模态、多任务、自万级Transformer模型	GPU A100 (128块)	图像文本转换 多模态文本转换

（注：原论文中为模型参数量随时间变化的趋势图，横轴为研发日期，纵轴为模型参数量（亿），标注了 MoE、GPT3、M6、PanGu、女娲等主流大模型的参数量与研发节点）

当前我国医学人工智能虽快速发展，但整体仍处于跟跑阶段，同时面临诸多行业痛

点：医疗数据因隐私保护难以共享、多源异构数据标准化程度低，针对疑难杂症缺乏高质量样本与高效算法，现有医疗 AI 模型与临床流程、医院信息系统的适配性不足，且还需应对医疗安全、伦理法律等特殊约束。在此背景下，探索医学大模型的构建与应用路径，成为推动我国医学人工智能突破发展的紧迫任务。

2 核心方法

研究围绕医学大模型的构建与应用，从基础概念界定、技术体系搭建、研发流程设计等方面提出了系统性方法，核心可分为以下几方面：

1. 明确大模型核心定义与训练范式

界定大模型为百亿级以上参数、可广泛适配下游任务的基础预训练模型，其经典训练模式为“预训练 + 精调”两阶段，同时 Zero-shot、One-shot 等小样本学习方法进一步提升了模型的通用适配能力。

2. 梳理大模型核心技术架构

以 Transformer 为基础架构，结合多头注意力机制实现全局信息学习与并行训练，BERT、GPT、DALL-E、BioBART 等主流模型均基于 Transformer 块进行功能结构扩展；同时融合 MoE（专家混合范式）、MMoE 等技术提升多任务学习效率；配套 Mesh-Tensorflow、DeepSpeed、MindSpore 等专用训练框架，解决大规模模型的分布式并行训练问题。

图 2 基于 Transformer 结构的常见模型分类

Figure 2 Model classification diagram based on a Transformer structure

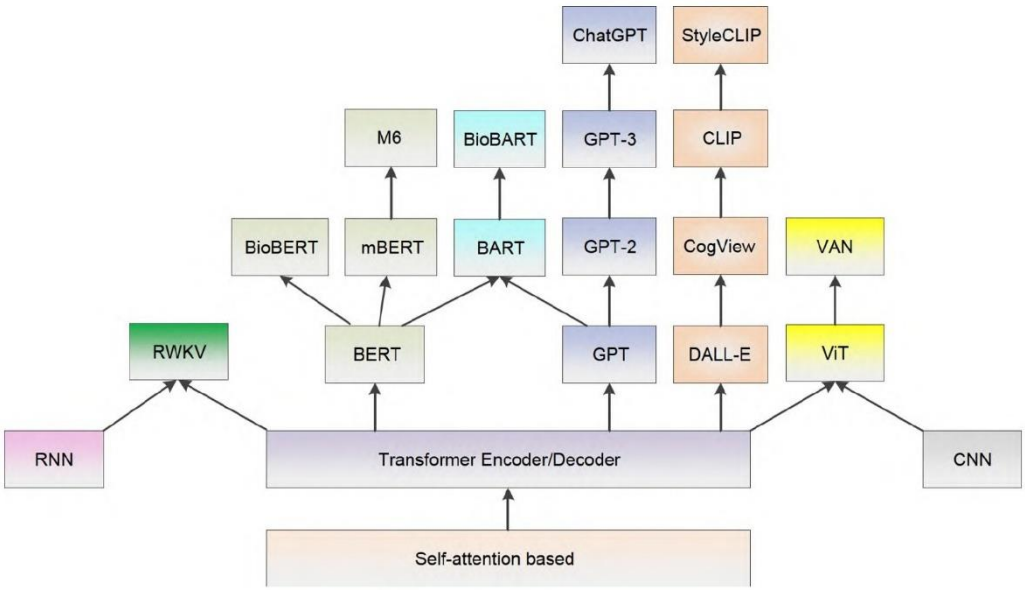

（注：原论文中该图以层级展示 Transformer 相关模型演化，底层为 RNN、CNN 基础网络，核心为 Transformer Encoder/Decoder，上层为 BERT、GPT、CLIP、BioBART、M6 等基于 Transformer 的衍生模型）

3. 提出模型优化多维度策略

从框架层面采用数据并行、模型并行、混合并行加速训练；数据层面提升样本质量、处理数据异常并引入混合精度、参数量化技术；结构层面通过模型压缩、网络剪枝、知识

蒸馏精简模型，结合动态网络、可变形注意力等增强模型适配性。

4. 制定医学大模型研发全流程

研究结合医学领域需求，统筹制定了涵盖数据处理、模型训练、验证测试、下游应用的全流程研发体系，具体包括多源异构医疗数据的预处理（遴选、清洗、脱敏、标注）、异构并行的大算力建设、结合医学需求的复杂算法构建，同时将伦理法律审查与个人隐私保护贯穿全流程，明确直接隐私保护（去标识、匿名化）与间接隐私保护（最小范围收集、风险研判）的具体要求。

图 3 医学大模型研发工作流程

Figure 3 Massively large artificial intelligence medical model research and development workflow

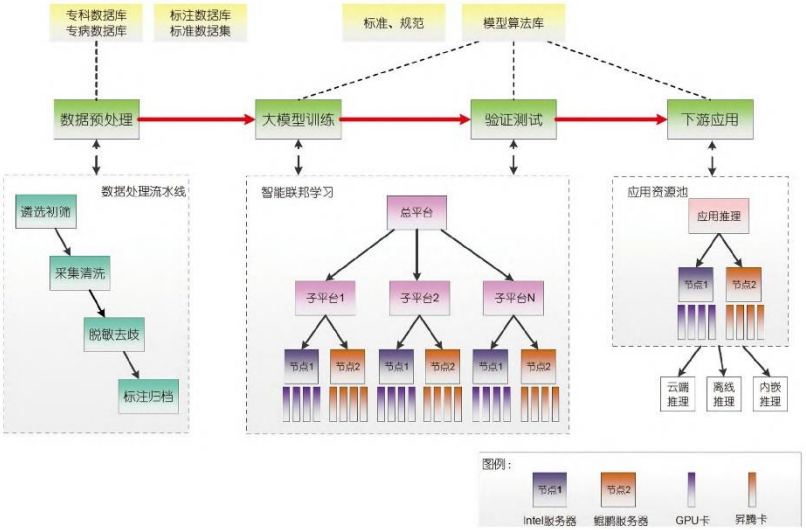

（注：原论文中该图展示了医学大模型研发的全链路，从专科 / 专病 / 标注数据库、标准数据集出发，经数据预处理流水线，依托智能联邦学习与分布式算力节点（Intel 服务器、鲲鹏服务器、GPU 卡、昇腾卡）进行大模型训练，再通过总平台与子平台完成验证测试，最终实现云端、离线、内嵌三种推理模式的下游应用）

5. 提出医学大模型两种研发策略

一是迁移训练，以通用大模型为基础，融入医学多模态数据进行再训练，适配特定医学场景，数据与算力需求相对适中；二是原生训练，借鉴通用大模型技术精髓，基于海量医学多模态数据，构建全流程创新的医学领域基础大模型，虽研发投入更高，但应用覆盖更宽广。

3 主要结果

1. 全面梳理国内外大模型发展格局

国外以美国为代表，在大模型理论研究、软硬件创新、全维度布局上占据先发优势，推出 BioBERT、ClinicalBERT、ChatDoctor 等生物医学专用模型，同时发布 MedQA、MIMIC-III 等标准数据集；国内大模型研发奋起直追，诞生 M6、PanGu-α、悟道文澜 BriVL 等多模态模型，以及余元、HuaTuo 等中文医学专用模型，同时构建了 CBLUE、CMeKG 等中文医学评测基准与知识图谱，不过在模型性能上与国际顶尖水平仍有差距

（如 GPT-4 在 C-EVAL 评测中准确率 68.7%，国内最优模型仅 49%）。研究还通过表格系统梳理了国内外著名大模型的参数量、训练数据、研制单位、应用领域等核心信息，为后续研究提供了详细参考。

2. 总结医学大模型关键技术突破

在医疗数据处理方面，提出 ME2Vec、Med-BERT 等适配电子病历（EHR）的嵌入方法，解决了医疗数据的时序性与图结构分析难题；在模型应用方面，解放军总医院的研发实践验证了医学大模型的实际价值，如基于 3D 肺 CT 的 COVIDNet 模型对新冠肺炎病灶识别准确率达 94.3%，深度学习模型可实现心脏瓣膜病的自动识别与病程分级，还开发了疾病进展风险与医疗花费评估框架，为临床决策提供支撑。

3. 构建医学大模型发展支撑体系

明确政策、协同创新、技术攻关、组织实施四大核心支撑要素。国家出台的健康大数据相关政策与数据安全、个人信息保护法律法规，为医学大模型研发划定了规范与底线；“产学研用”一体、“理工医信”结合的协同创新机制，成为突破行业资源壁垒的关键；迁移训练成为当前医学大模型研发的可行路径，而原生训练则是长期发展方向；同时提出需整合医院、企业、高校、科研院所等多方力量，构建自主可控的医学大模型产业服务平台。

4 个人小结

本研究是国内医学人工智能领域关于大模型应用的系统性综述与实践总结，其核心价值在于首次全面勾勒出医学大模型的技术脉络与发展路径，填补了国内该领域系统性研究的空白。研究不仅清晰界定了医学大模型的基础概念、核心技术与研发流程，更结合我国医疗行业的实际痛点，提出了兼具可行性与前瞻性的研发策略，为后续医学大模型的研究提供了统一的理论框架与实践参考。

研究明确了我国医学大模型发展的现状：虽在中文医学数据处理、专用模型研发上取得初步突破，但与国际顶尖水平相比，在模型性能、算力支撑、原创算法等方面仍存在差距，同时面临数据共享困难、跨领域协同不足、伦理隐私保护等共性问题。而解决这些问题的关键，在于依托国家政策支撑，构建跨机构、跨领域的协同创新体系，在现阶段优先采用迁移训练实现医学大模型的快速落地，同时持续布局原生训练的核心技术攻关，突破算力、算法、数据等核心要素的瓶颈。

此外，研究将伦理法律规范与个人隐私保护作为医学大模型研发的重要前提，契合医疗行业的特殊性，为医学人工智能的健康发展划定了红线，也为后续相关标准与规范的制定提供了参考。总体而言，该研究不仅为医学大模型的研发实践提供了具体指导，更揭示了人工智能与医学深度融合的核心逻辑 —— 技术创新需围绕临床需求，同时兼顾合规性与实用性，这也为未来“AI + 医疗”的发展指明了方向：唯有以临床需求为导向，以技术创新为核心，以协同共享为路径，以规范保障为基础，才能推动医学大模型真正赋能医疗健康事业，实现从技术突破到临床价值转化的跨越。